

8. Decisiones tecnológicas y su justificación

Decisión	Alternativas consideradas	Justificación
Stack backend	FastAPI vs Django vs Flask (Node.js Express)	FastAPI: alto rendimiento async, tipado con Pydantic, documentación Swagger automática, ecosistema Python natural para IA/OCR.
Stack frontend	React + Vite vs Angular vs Vue	React 18 + TypeScript + Vite: ciclo de desarrollo rápido, tipado seguro y amplia comunidad; SPA adecuada para una aplicación interna.
Base de datos	PostgreSQL 16 + pgvector vs MySQL vs MongoDB vs Chroma	PostgreSQL relacional + pgvector: integra metadatos estructurados, texto y vectores en un solo motor con índices HNSW; evita bases vectoriales dispersas.
Servicio de IA	OpenAI (embeddings + gpt-4o-mini) vs Gemini vs LLM local (Ollama)	OpenAI: calidad y velocidad consistentes, instalación cero en el contenedor, adecuado para la sustentación; el módulo interno permite cambiar a LLM local por variables de entorno.
OCR	PaddleOCR vs Tesseract vs Cloud OCR	PaddleOCR: mejor precisión en documentos en español y facturas; se complementa con Tesseract como respaldo sin costo adicional.
Almacenamiento de archivos	MinIO (S3) vs carpeta local vs AWS S3	MinIO: estándar S3 local, dockerizable, sin depender de nube externa en la demostración; configurable por variable de entorno.
Despliegue	Docker Compose vs instalación manual vs PaaS	Docker Compose: reproduce el entorno completo (BD + API + front + IA) en cualquier máquina de forma confiable para la entrega.
Autenticación	JWT vs sesiones vs OAuth	JWT stateless: simple, escalable y suficiente para el alcance; compatible con la SPA.
Búsqueda	pgvector + ILIKE híbrida vs Elasticsearch vs BM25 puro	pgvector + ILIKE: búsqueda semántica + textual en el mismo motor, sin infraestructura adicional para el volumen del caso.